THE AUSTRALIAN NATIONAL UNIVERSITY / COMP8800

FINAL SYNTHESIS • DOCUMENT 3 + DOCUMENT 4 + ORIGINAL EVIDENCE

JHQ-GPU Master Thesis Blueprint

研究型硕士论文最优合并版

Representation-Aware GPU ANN Search and Workload-Level Refinement Calibration

27,500	9	53	90+
建议英文正文词数	研究章节	逐节写作卡	质量标准参考，并非评分保证

让每条结论都能沿着 **问题 → 替代设计 → 实际机制 → 正确性条件 → 受控实验 → 适用边界** 被审查。

以你的代码、GPU 实验、ADC 论文及海报为核心；以可反驳的研究发现，而不是堆砌算法名词，证明工作价值。

整理日期
26 October 2026

研究载体
COMP8800 / JHQ-GPU

证据基准
GitHub main @ 70da383；本地较新数据待核

文件性质
写作蓝图与审稿标准，不是正式 Thesis

编辑结论：35 页版本为底稿，22 页版本负责纠错

维度	3(1).pdf · 35页	4(1).pdf · 22页	最终合并处理
写作颗粒度	53 节，逐节说明目标、论证、证据和技术红线	51 节，文字紧凑，实验章节略更突出	保留 53 节，但明确每节一次性职责，避免重复
技术证明	形式证明清单更丰富；5.5 混入 partial-distance pruning	v63 complete-key bound 的表述更接近实作	以实际 v63 为准，重写 bound 的充分条件和省工机制
实验组织	证据注册表与三级来源标签清楚	E1/PIPE/OPT 数据对照和引用更易读	将 repository report / historical / user-supplied 分层；所有主张有源表
出版与可用性	35 页，原 PDF 无链接注释	22 页，含可点击参考链接	保留多维度细节、缩短过长空白、提供可点击论文/代码入口
核心篇幅	Ch5 5300、Ch7 6200	Ch5 5000、Ch7 7000	Ch5 5300、Ch7 6800；方法证明和实证均保留充足空间

最终选择：两份都保留九章主线，但重新分配章节职责；全文 27,500 词，4–7 章 17,900 词（65.1%）。实际稿件长度以内容与 Canvas 最新要求为准。ANU 给出的典型参考为 25,000–30,000 词、约 50–60 页，有合理变动空间。

需要纠正的三个关键技术点

问题	最终写法
v63 shared bound	每个 candidate 仍计算完整 primary score；完整 local k-th key 提供全局 top-c 的上界，允许跳过部分接纳/排序/merge。没有实现 partial-sum early-exit。
确定性排序键	优先按源码使用 **(primary score, stable position)**；不能将唯一物理 position 偷换为原始 ID。NaN/±0/ties 的比较约定需单独写清。
v69/v71 新数字	22/24、1.03–1.69×、3.9–21.3 ms 是用户提供的 Codex 线索，当前公开 main 未见原始件；既不冒充复核，也不回退到旧 ADC 当作最新数字。

学术身份限制：所使用的“Honours theses: Marking guide”是用户提供的 ANU Honours 评分指南，可作为冲击高分的研究质量标尺；并不能未经课程方确认便当作 COMP8800 正式逐项计分表。“90+”指写作目标，不代表已经达到或保证最终分数。

先读：评分人究竟在检查什么

质量维度	80–89 的可靠表现	按 90+ 目标应额外证明
Critical literature	批判分析相关文献，清楚定位领域	解释替代路线的前提与失效情况，说明为什么采用当前路线。
Technical mastery	掌握 GPU/ANN/量化的核心技术	给出可审查的 top-c 与 bound 不变量、源码映射、reference 验证。
Independent research	独立提出并实施有效想法	通过 GO / NO-GO 与反例，展示对自己假设的批判性验证和决策。
Originality & outlook	了解实验限制，提出可行方向	从现有数据推出有原创性且可反驳的未来命题、最小检验方案。

质量维度	80–89 的可靠表现	按 90+ 目标应额外证明
Research standard	结构完整，数据清楚	若追求发表级标准，所有强结论需有匹配版本、统计可靠性与适用边界。

一条主张的完整证据链

Claim → source version → reference semantics → paired change → result + uncertainty → boundary → alternative explanation.

一项独立研究的完整决策链

Hypothesis → GO/NO-GO criterion → implementation or pilot → counterevidence → iteration → decision.

研究论证主线：四个 RQ 与三项贡献

Research question	方法章节	必须用来回答的证据
RQ1：建库、物理布局与内存/规模成本?	Ch4	Ch7.7 训练/编码、resident/peak、test scale。
RQ2：Cartesian LUT、global top-c 和调度何时正确、何时更快?	Ch5	Ch7.3–7.4、7.6：形式条件 + reference tests + paired stage time。
RQ3：sampled α 比固定预算的质量/净成本如何?	Ch6	Ch7.5：held-out recall、fixed small、enumeration、full-pool、oracle、payback。
RQ4：和强 GPU ANN 系统比，优势区域与边界?	Ch2–3	Ch7.2：完整 recall–QPS Pareto、统计波动、显存与 build。

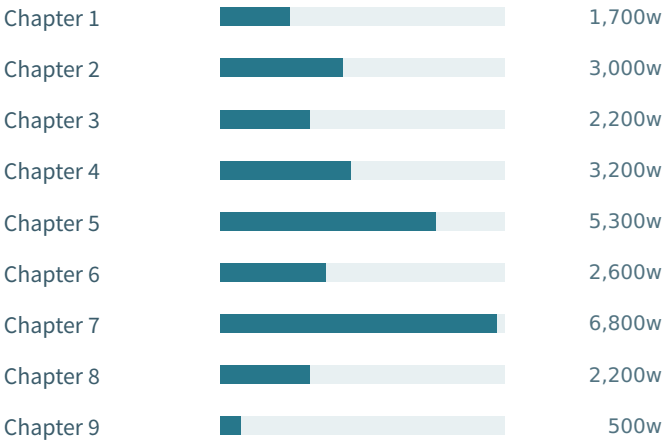
Inherited JHQ rotation · Cartesian primary · residuals → **GPU mechanism** LUT · global top-c · shared key → **Budget policy** agreement · α · risk → **Measured region** recall · QPS · build · bytes

贡献定义：C1 完整 GPU JHQ 系统及建库/查询/内存实现；C2 表示感知的精确候选选择、LUT 和并行执行；C3 工作负载预算校准及跨层结果。继承的 JHQ 数学与通用 GPU primitive 不应包装为原创算法。

九章最终结构与字数预算

章	英文标题	建议词数	核心交付
01	Introduction	1,700	研究定位、贡献与边界
02	Background and Critical Related Work	3,000	批判性比较而非文献摘要
03	Research Design and Measurement Methodology	2,200	实验可复查、比较公平、主张可反驳
04	System Architecture and GPU Index Construction	3,200	从继承表示到可运行、可计量的索引
05	Representation-Aware GPU Search Execution	5,300	全文最重要的算法、实现与正确性章节
06	Workload-Level Refinement-Budget Calibration	2,600	只改变工作量预算，不混入线程调度
07	Experimental Evaluation and Research Findings	6,800	以原始实验回答四个研究问题
08	Discussion, Limitations and Future Research	2,200	从结果提炼可迁移的研究认识
09	Conclusion	500	逐项回答研究问题，不能新造数字

篇幅结构



章节责任边界

Ch3 / Ch7：前者规定实验如何设计与审计，后者给实际配置和结果。

Ch4 / Ch5：前者讲如何存与建库，后者讲如何读、并行、选候选。

Ch5 / Ch6：前者分配 GPU 执行资源，后者选择 refinement 候选预算。

Ch7 / Ch8：前者报告受控观察，后者提出可推广解释、替代原因和负结果。

> 建议先固定 **Ch7 的实验主张与来源**，再写 Ch5 的证明和执行实现、Ch4 的架构、Ch6 的预算方法。Introduction 与 Conclusion 最后回填；这比按目录顺序硬写更容易保持数据与方法一致。

目录（可点击跳转）

01 Introduction — 1,700 words
研究定位、贡献与边界

02 Background and Critical Related Work — 3,000 words
批判性比较而非文献摘要

03 Research Design and Measurement Methodology — 2,200 words
实验可复查、比较公平、主张可反驳

04 System Architecture and GPU Index Construction — 3,200 words
从继承表示到可运行、可计量的索引

05 Representation-Aware GPU Search Execution — 5,300 words
全文最重要的算法、实现与正确性章节

06 Workload-Level Refinement-Budget Calibration — 2,600 words
只改变工作量预算，不混入线程调度

07 Experimental Evaluation and Research Findings — 6,800 words
以原始实验回答四个研究问题

08 Discussion, Limitations and Future Research — 2,200 words
从结果提炼可迁移的研究认识

09 Conclusion — 500 words
逐项回答研究问题，不能新造数字

证据冻结：哪些数字现在能用、哪些还要核对

下表中的 **REPO-REPORTED** 表示目前可读取的 GitHub 报告明确载有该结果；不表示我已重跑全部原始日志。**USER-REPORTED** 是本轮 Codex 文本转述；**HISTORICAL** 是具有明确旧实验版本的数字。

来源	性质	关键内容 / 约束
E1 ↗	REPO-REPORTED	四数据集对外 benchmark；RTX 5090、batch 1000、k=10。0.97 处约 231/259/127/56k QPS（Vogue/arXiv/OpenAI3-1536/3072）。
E1 FAIR ↗	REPO-REPORTED	matched-recall 插值、workspace 与显存计时；JHQ 与对手显存口径不同。
PIPE ↗	REPO-REPORTED	v61 L16→v65：b8 几何平均 2.73×；b1000 1.015×；shared full-key bound、调度、失败 pilot。
PIPE V62 ↗	REPO-REPORTED	global primary top-c 的 exact local-top-c + merge 证明及 64 组对照；tie 语义。
OPT ↗	REPO-REPORTED	v69 exact probe：1792 case、0 failure；b8 probe stage 53–78→15–23 µs；v70 FP16 route 为近似。
MAIL ↗	REPO-REPORTED	真实 GPU isolated scoring 仅为基线 0.19–0.58×；无端到端集成。
RANK ↗	REPO-REPORTED	数学、排序/重构误差取舍，GPU 未实现完整 rank-optimal kernel；median 后续另有实测。
ADC HIST ↗	HISTORICAL	旧 ADC LUT 23/24、预算 1.05–2.77×、校准 5.2–30.8ms 等只作为历史结果。

尚未核实的较新数字

ID	来自 Codex 的结果线索	在 Thesis 中的状态
LUT-v71	G=2 最优 22/24；另两项差距 <1%。	用户粘贴的 Codex 审阅；v71 独立 commit、bin、raw 尚未在可访问 main 中核对。
CAL-v69	10/12 selected-arm QPS 为 1.03–1.69×；S=128 约 3.9–21.3 ms。	Mac 本地 experiments/adc_v69/REPORT_CN.md、RAW/budget_v69.log 尚未读取。
LARGE-NEW	更新后的大数据集重测与 baseline 修正。	需提供真实 index/GT/build config、提交 SHA 和 RAW，不预填新版性能。

> **一条底线：**没有 commit / binary / index / query / raw / parser 的可追溯链时，不把新数字放进 Abstract 或 Conclusion。旧 ADC 数字只注明旧版本，不能拼成 v71/v69 的新 frontier。

每条重要主张的最小 evidence ledger

claim_id · git_sha · executable · compiler_flags · GPU/driver/CUDA/cuVS · index_hash · training_sample · dataset_N/d/metric · query_set/split/seed · k/nprobe/alpha/batch · timing_scope · warmup/repeats · reference_semantics · raw_log/hash · analysis_script · figure/table · validity_status.

建议为 E1、LUT-v71、GLOBALTOPC、THRESHOLD、PROBE-v69、PIPE、CAL-v69、LARGE、MAIL 各维护独立 ledger 行。历史实验运行版本与最终提交源码版本可以不同，必须说明。

CHAPTER 01 • 1,700 ENGLISH WORDS • 6 SUBSECTIONS

Introduction

研究定位、贡献与边界

EXAMINER QUESTION

前 3 页能否回答：为什么值得研究？哪部分是继承的 JHQ，哪部分确实由这个 GPU 项目完成？

REQUIRED DELIVERABLE

问题—挑战—方案图；四个 RQ；三项带证据归属的贡献；范围声明。

1.1 Context and Practical Objectives

300 words

写什么 以 768–3072 维 embedding 检索为背景；明确 recall、host-to-host QPS/latency、resident memory、cold build 四个代价轴。

要论证 从一次真实查询流水线引出低码长不自动意味着低 GPU 延迟；用扫描与精排代价作动机。

数据 / 图 E1 / PIPE / JHQ; Faiss; GPU IVF-RaBitQ • F01

技术红线 不要用 RAG 流行度替代具体研究挑战；不宣称已验证 1B / S3。

1.2 Problem Definition and Scope

280 words

写什么 定义数据库 X、查询 q、top-k，区分 D_raw、D_primary 与 D_refined；约束单 GPU、JHQ 表示、IVF 路由与分层精排。

要论证 把“按 primary score 精确选 top-c”与“找原始距离的真正 top-k”严格区分；指出 k=10、E1 batch=1000 是已测配置而非所有情形。

数据 / 图 ADC / JHQ / E1 FAIR • 定义框

技术红线 不得把量化精排称为 FP32 exact rerank；不得把 GPU-native 误解为所有路径设备常驻。

1.3 Three Linked Technical Challenges

300 words

写什么 挑战一：Cartesian 主码与 GPU LUT 资源；挑战二：单查询 block 与大规模全局 top-c；挑战三：精排预算的质量与总成本。

要论证 对每个挑战给出可观察瓶颈、可选设计和可反驳的性能命题。probe 选 list 与 primary 选向量是两个选择问题。

数据 / 图 LUT-v71 (待核) / PIPE / CAL-v69 (待核) • 挑战→机制→证据图

技术红线 不能把已观察的收益写作未经测试的事前假设。

1.4 Research Questions and Falsifiable Claims

320 words

写什么 提出 RQ1 建库/物理布局、RQ2 正确且高效的 GPU 搜索、RQ3 预算策略的风险和摊销、RQ4 与 GPU ANN 的竞争区间。

要论证 每一项必须对应第 7 章一张主图或数据表，并列出会否定主张的观察；区分 exploratory analysis。

数据 / 图 RQ-C-E matrix / E1 / PIPE / CAL • 四行 RQ→方法→指标表

技术红线 不要提出“是不是全世界最快”这种无法用现有数据验证的 RQ。

1.5 Contributions and Research Ownership

400 words

写什么 C1 完整 GPU index/build/search；C2 利用 Cartesian 表示的 LUT、global top-c、shared threshold 和 lane refine；C3 workload calibration 和跨层实证。

要论证 每项按“继承 → 个人/项目改动 → 正确性 → 结果 → 条件”写；只称系统机制适配与实证，不抢占原有算法优先权。

数据 / 图 JHQ original / CODE IDX+SEARCH / PIPE / E1 • 贡献归属矩阵

技术红线 不能把 JHQ、bitonic/radix、CUDA Graph 或普通 list splitting 当作首次发明。

1.6 Thesis Roadmap

100 words

写什么 用极简一段连接 Ch2–3 背景与方法、Ch4–6 设计、Ch7 数据、Ch8 认识、Ch9 答案。

要论证 只导航，不重复贡献与摘要。

数据 / 图 全篇结构 • 章节导览

技术红线 控制在约 100 词。

章节校验： 本章 6 小节，建议 1,700 词。只将经过证据登记的数字写入强结论。

CHAPTER 02 • 3,000 ENGLISH WORDS • 7 SUBSECTIONS

Background and Critical Related Work

批判性比较而非文献摘要

EXAMINER QUESTION

能否解释至少三类替代系统在数据表示、候选访问、精度和成本上的真实差异?

REQUIRED DELIVERABLE

术语与技术谱系；JHQ 继承边界；GPU/量化/图方法比较；一张设计取舍总表。

2.1 Formal ANN Objective and Metrics

300 words

写什么 定义 top-k、Recall@k、QPS、batch latency、Pareto frontier、build time、bytes/vector；明确匹配 recall 插值与实测点。

要论证 解释 GT、distance metric、ties 和参数网格会改变比较的意义；尽量建立全文唯一记号表。

数据 / 图 PQ / Faiss / E1 fairness • 符号表

技术红线 不要在曲线端点之外外推。

2.2 IVF, PQ, ADC and Residual Refinement

450 words

写什么 讲清 coarse list、PQ/ADC、codebook、lookup、候选截断与 residual refinement 的数据依赖。

要论证 区分 IVF-centroid residual 与 JHQ primary reconstruction residual；推导前一阶段遗漏无法由下游精排恢复。

数据 / 图 PQ / Faiss / JHQ • F02：两级候选缩减

技术红线 “residual”不是单一概念，不得把量化重构等价于 raw full-vector exact。

2.3 Inherited JHQ: Rotation, Cartesian Codes and Assumptions

650 words

写什么 解释正交变换、逐维标量码本、Cartesian 子码组合、1-bit-per-coordinate 主码与层次 residual；写主要 score 公式。

要论证 明确正交旋转保 L2，但不等同于降维 JL；码本分解依赖可加结构；高斯/独立假设是模型假设。

数据 / 图 JHQ PVLDB 2026；原 JHQ 海报；CODE IDX • F03：Inherited JHQ 算法链

技术红线 原 JHQ 数学方法不能作为本文新贡献。

2.4 GPU Execution Concepts Used Here

300 words

写什么 只保留实际用到的 SIMT、warp、shared/global、coalescing、occupancy、同步与 graph capture。

要论证 每个硬件概念连接 Ch5 某项设计及其测量指标；roofline 只能作为解释，不替代 GPU counters。

数据 / 图 Faiss GPU / NVIDIA / PIPE • 资源—机制—证据表

技术红线 无 counters 时不要把性能变化说成已实测的带宽饱和。

2.5 GPU Graph Search: SONG, CAGRA and BANG

350 words

写什么 从 graph construction、GPU 常驻、查询数据依赖、跨设备协作、压缩评分几个维度比较。

要论证 指出强图基线的不同有效区间；不要用论文中不同硬件的 speedup 与你的 RTX 5090 数字直接相除。

数据 / 图 SONG / CAGRA / BANG；E1 • 方法对照表

技术红线 BANG 的 billion-scale 能力不能转移为本系统的容量声明。

2.6 Quantised ANN, Fast Tables and Modern Alternatives

550 words

写什么 重点比较 GPU IVF-RaBitQ、Faiss IVF-PQ、RaBitQ/multi-bit、Quicker ADC、OPQ/ScaNN 与 GPU top-k。

要论证 针对编码开销、LUT 可分性、score fidelity、内存、global selection 和可运行 recall 的区间提出可验证差异。

数据 / 图 GPU IVF-RaBitQ / Quicker ADC / Faiss / SC23 top-k • P0 设计矩阵

技术红线 small LUT、radix、table splitting 等已有先行工作，不宣称概念首次提出。

2.7 Critical Synthesis and Precise Research Gap

400 words

写什么 把文献变成“约束—替代方案—成本—本研究抉择—尚未解决”的结论表。

要论证 论证为何 JHQ 的 Cartesian 表示在 GPU 上值得研究，也说明为什么不选择更复杂的 learned representation 或纯图方案。

数据 / 图 前六节 + 自己的系统/消融 • 研究定位总图

技术红线 不能用笼统的“缺少 GPU 实现”替代新颖性论证。

章节校验：本章 7 小节，建议 3,000 词。只将经过证据登记的数字写入强结论。

CHAPTER 03 · 2,200 ENGLISH WORDS · 6 SUBSECTIONS

Research Design and Measurement Methodology

实验可复查、比较公平、主张可反驳

EXAMINER QUESTION

任何结果可否追溯到一份实际运行时的 commit、二进制、索引、查询和分析脚本?

REQUIRED DELIVERABLE

统一 protocol；manifest schema；公平性判定；证据等级；不在 Ch7 重复解释。

3.1 Research Questions as Controlled Comparisons

450 words

写什么 为每个 RQ 指定 treatment/control、固定变量、性能指标与可能反例：LUT 组数、分组扫描、预算策略、竞争系统。

要论证 性能假设与见数据后提出的解释分开；相关性与因果性分开；低 recall 和高 recall 不利结果同样报告。

数据 / 图 LUT / PIPE / CAL / E1 · RCT-like comparison matrix

技术红线 不要伪造预注册；“agreement 不是 recall”是定义边界而非普通统计假设。

3.2 Datasets, Queries, Ground Truth and Splits

350 words

写什么 逐行记录 N、d、metric、归一化、train/cache、query/held-out、seed、GT、k；区分 ADC 六数据集和 E1 四数据集。

要论证 确定 v69 budget 的采样/留出集合，不沿用旧 ADC 的 query split；必要时把未核信息标 PENDING。

数据 / 图 E1 manifest / ADC / CAL local · dataset manifest

技术红线 不能因 GT 截断、重复 query 或不同数据版本造成虚假对比。

3.3 Measurement Boundary, Variance and Memory Accounting

420 words

写什么 定义 host-to-host、GPU kernel time、单 batch latency 与 steady-state QPS；说明 warmup、replications、设备/驱动、功耗、索引载入方式。

要论证 显存拆为 index、workspace、context、resident/peak；对微小速度差报告配对波动，不根据单轮测量断言显著胜负。

数据 / 图 E1 FAIR / RAW / PIPE stages · F04：API+测时边界

技术红线 不可把 JHQ process-minus-context 与 CAGRA index-only 视作同一显存口径。

3.4 Baselines, Tuning Grids and Frontier Construction

430 words

写什么 说明 CAGRA fp32/int8、IVF-PQ、IVF-RaBitQ 和 exact GPU brute force 的独立参数 sweep、共同距离/GT。

要论证 解释非支配点、log-QPS interpolation、无覆盖 recall 点、重复调用异常值和 matched-recall 两种读数。

数据 / 图 E1 FAIR / E1 matched / raw · Pareto 构建流程

技术红线 不能只报较弱 baseline 或删除真实不利区间。

3.5 Versioned Claim-to-Evidence Ledger

350 words

写什么 每条主要主张记录 SHA、build flags、binary hash、index fingerprint、query split、metric、raw、parser、plot、异常。

要论证 最终交付源码快照与历史真实运行快照分开；v71、local adc_v69 和大集重测原始数据未读前不得标已审计。

数据 / 图 E1 / PIPE / OPT / CAL local · 唯一来源 registry

技术红线 不要用 main 最新代码替代某张历史图对应的实际二进制。

3.6 Evidence Strength and Threat Controls

200 words

写什么 给出 formal proof、reference correctness、paired microbenchmark、end-to-end measurement、model estimate、unverified claim 六类证据标签。

要论证 声明每类允许支持的结论以及未覆盖的条件；为 Ch8 因果解释预留竞争解释。

数据 / 图 RUBRIC / EVID registry · 证据强度标记

技术红线 不能把 cost model 当作真实 GPU measured endpoint。

章节校验：本章 6 小节，建议 2,200 词。只将经过证据登记的数字写入强结论。

CHAPTER 04 · 3,200 ENGLISH WORDS · 6 SUBSECTIONS

System Architecture and GPU Index Construction

从继承表示到可运行、可计量的索引

EXAMINER QUESTION

读者能否从输入、训练、码本、IVF、物理字节一直追踪到 GPU resident index 与临时缓冲?

REQUIRED DELIVERABLE

系统架构图；建库 DAG；物理地址公式；bytes/vector；reference correctness contract。

4.1 End-to-End Build and Search Boundaries

400 words

写什么 画冷构建路径与查询路径两条 DAG，标 CPU/GPU 责任、index snapshot 与 CUDA graph 的位置。

要论证 列出 rotation、centroids、list assignment、primary/residual、ID/position、query LUT、buffers 的输入输出和生命周期。

数据 / 图 jhq_v69_probesel/jhq_gpu_index.cu + search.cu · F05：build/query architecture

技术红线 未实现的 S3、block streaming、异构分布式路径不得画成实线。

4.2 Training, Rotation and Codebook Generation

550 words

写什么 写训练样本、正交矩阵、coarse K-means、Cartesian primary quantisation、residual quantizer 的依赖顺序和 GPU kernel。

要论证 区分算法数学由 JHQ 继承、你如何在 GPU 上训练/编码/批处理、构建中间态的时间与容量；加入计算复杂度和误差条件。

数据 / 图 JHQ original / build code / train logs · 训练→编码 DAG

技术红线 不将高斯分布假设写成“所有数据经旋转后都标准正态”。

4.3 IVF Assignment, IDs and Physical Memory Layout

650 words

写什么 定义 nlist、list offsets、stable position 与原始 ID 的双向映射；展示 logical codes 与 word-packed physical view、residual 层存储。

要论证 列至少一个精确地址公式，解释 per-list reorder 与扫描连续性；实存字段与临时 transpose/copies 一一对应。

数据 / 图 CODE IDX / CODE SEARCH · F06：list→position→packed bytes

技术红线 本章只讲如何存和编码；warp 如何加载留第 5.3 节。

4.4 Resident Storage, Workspace and Index Lifecycle

500 words

写什么 分类核算主码约 d/8 B/vector、残差约 d B/vector（仅适用相应层数和编码设置）、IDs、metadata、LUT、workspace、context、peak。

要论证 给真实配置的 bytes/vector 及构建峰值；解释减小 alpha 是少读/少算，不自动减少完整常驻 residual。

数据 / 图 ADC memory / E1 FAIR / build output · 静态/峰值/搜索工作集表

技术红线 不要把不同方法的 process-minus-context 与 index-only 数字写成严格同口径。

4.5 Construction Cost and Tested Scale

550 words

写什么 分解训练、旋转、主码/残差编码、IVF assignment、reorder、finalisation 与 cache loading。

要论证 并列理论计算代价、cold build wall time、GPU peak；旧 ADC 17.8M 可以作为历史实测， newer large retest 未提供需待核。

数据 / 图 ADC / older large build / newer large PENDING · F07：建库耗时与显存

技术红线 不能用 17.8M 推断实现已达到 1B；不可把 cache load 当 cold build。

4.6 Index Representation and Safety Contracts

550 words

写什么 从 CPU/FP64 reference 审核编码、rotation isometry、codebook reconstruction、list offset、unique stable position、ID inverse mapping。

要论证 给清楚的定义、对抗性输入、误差容差以及数据结构不变量；把该层正确性与搜索 top-c、最终 recall、sanitizer 明确隔离。

数据 / 图 CODE IDX / CORR-ENC (如已具备) / tests · correctness C0–C1 表

技术红线 sanitizer 不是算法正确性的证明，same recall 也不是输出等价证明。

章节校验：本章 6 小节，建议 3,200 词。只将经过证据登记的数字写入强结论。

CHAPTER 05 · 5,300 ENGLISH WORDS · 7 SUBSECTIONS

Representation-Aware GPU Search Execution

全文最重要的算法、实现与正确性章节

EXAMINER QUESTION

能否从 primary score 定义证明 global top-c，并解释 shared bound 的 GPU 实现与不同 batch 的成本?

REQUIRED DELIVERABLE

形式证明 + 线程/地址映射 + 拆表成本 + 精排协作 + probe 独立验证；对接源码与消融。

5.1 Query Path and Four Distinct Ranking Objects

450 words

写什么 给出 centroid/probe score、D_primary、D_refined、D_raw 四种排序对象；详细走 query transform→route→LUT→scan→top-c→refine→top-k。

要论证 对每阶段列输入候选数、读的编码、输出集合和主成本；明确在固定 probe 集合上的“exact primary top-c”不等于 true exact kNN。

数据 / 图 CODE SEARCH / JHQ / PIPE phases · F08：两个 selection 节点的查询路径

技术红线 不能把 centroid-probe selection 与 primary-vector selection 合并成一个过程。

5.2 Exact Cartesian LUT Factorisation

800 words

写什么 在分离的子空间中推导 L(i,j)=L_A(i)+L_B(j)；一个 256-entry subcode LUT 能重写成两个 16-entry sub-LUT（32 entry）。

要论证 比较 G=1/2/4/8 的表大小、lookup 次数、ADD 数、同步和 shared-memory 占用，解释为什么最小表不必然最快；对照 Quicker ADC 的先例。

数据 / 图 ADC M1 historical；v71 22/24 USER-REPORTED 待原始日志 · F09：数学分解与资源 trade-off

技术红线 数学等价不等于 FP bitwise equality；不能称一般任意 PQ 码本均可 exact split。

5.3 Packed Codes and Candidate-Parallel Memory Access

600 words

写什么 给出 (list, position, subspace)→地址映射；warp lane 如何按候选做 32-bit word loads 与子码表访问。

要论证 区分物理 transpose、packed instructions、memory coalescing、实际读取字节；展示独立 on/off 实验能否分离贡献，不能时写明限制。

数据 / 图 CODE SEARCH / ADC M1 / word layout history · F10：warp-lane×word 访问图

技术红线 packing 常降低指令/寻址开销，并不必然减少有效载荷字节。

5.4 Exact Global Primary Top-c via Multi-Block Scanning

1,200 words

写什么 设 U=∪U_g 为已访问 candidates，严格全序 key=(primary score, stable position)，每组保留精确 local top-c；经过 pairwise merge-path 后只保留前 c。

要论证 证明 Top_c(U)=Top_c(∪_g Top_c(U_g))；讲空/短组、G×c scratch、INF sentinel、tie、position 唯一性与 merged key；比较 v61 的旧 tie policy 与 v62/v65。

数据 / 图 PIPE_V62 § §1–3 / actual v62 search.cu / consistency dumps · F11：local top-c 覆盖+全局 merge

技术红线 严格等价依赖局部选择器自身精确；local quota<c 不是无条件安全；1792 probe tests 完全不支持此命题。

5.5 Shared Complete-Key Thresholds and Execution Scheduling

800 words

写什么 写 v63 的真实机制：每组完成 full primary score 后发布自己第 c 小 (score, position) key；atomicMin 共享有效的全局上界。

要论证 严格说明 local kth key ≥ global kth key，故 key 大于已发布 bound 的候选可跳过局部接纳/维护；不会跳过完整 primary score 计算。再讲 B×G 并行、额外 staging/merge、v65 按 batch 与 CV 选 G 的规则及失效情况。

数据 / 图 PIPE master + v63/v65 search.cu; v62→v63 controlled comparison · F12：shared key 的发布/剪枝流；调度成本

技术红线 **关键修正**：当前 v63 不是 partial-distance lower-bound early exit；那种优化仅可作为未来提案。stale bound、tie、NaN/negative score 须界定。

5.6 Lane-Cooperative Residual Scoring and Final Top-k

700 words

写什么 说明 top-c 后才读取残差，warp/lane 对候选与坐标的映射、协作归约、精排分数、final top-k。

要论证 比较单 lane 与 L16：减少串行工作但增加 shuffle/reduction/occupancy 开销；报告 FP 顺序、tie 对结果的影响及随机 residual 访问。

数据 / 图 v61 warp refine / PIPE phase timing / reference refine checks · F13：lane-by-dimension 图

技术红线 残差重建精排不等于读取 raw FP32 的精确重排。

5.7 IVF Probe Selection as an Independent Primitive

750 words

写什么 单列 centroid scores 中选 nprobe 个 lists；从 v65 bitonic 到 v69 4×8-bit radix selection、稳定 tie by list ID、offset scan。

要论证 单独解释 1792 个 adversarial cases、stage latency 53–78→15–23 µs（b=8）；说明 v70 FP16 routing 是不同的近似数值路径，不保证 identical probe IDs。

数据 / 图 practical_opt/FINAL_REPORT_CN.md / v69 search.cu • F14：probe vs top-c 两种选择的参考测试

技术红线 不得把 radix 叫首次发明；FP16 route recall 相同不代表 probed list 完全相同。

章节校验：本章 7 小节，建议 5,300 词。只将经过证据登记的数字写入强结论。

CHAPTER 06 • 2,600 ENGLISH WORDS • 6 SUBSECTIONS

Workload-Level Refinement-Budget Calibration

只改变工作量预算，不混入线程调度

EXAMINER QUESTION

无 GT 的 agreement rule 相对固定预算到底减少了什么、冒了什么风险、多久才能回本?

REQUIRED DELIVERABLE

预算选择规则、条件单调性、对照设计、质量/速度/校准成本三个维度。

6.1 Why Fixed Refinement Budgets Can Be Wasteful

350 words

写什么 解释 c=αk 是精排候选数，不等于 nprobe；candidate buffer、kernel stage、per-candidate refined-score 成本共同决定最优 α。

要论证 以 cost model T(α)=constant+primary_select(α)+refine(α) 描述假设，但不能先断言 α 越小就一定快。

数据 / 图 ADC M2 / PIPE / CAL v69 pending • budget cost diagram

技术红线 工作负载级参数选择不等于逐 query 的 learned router。

6.2 GT-Free Sampled Output Agreement

500 words

写什么 对 S 条 calibration queries 定义 $D(\alpha)=\Sigma\,[k-|R_\alpha(q)\cap R_{ref}(q)|]$；说明 reference α_ref、epsilon 与使用的预算网格。

要论证 展示“全然与错误 reference 一致”不能保证 GT recall；固定 epsilon 增加 S 时容忍的错误比例 epsilon/(S*k) 也在降低。

数据 / 图 ADC methods / v69 budget raw PENDING • F15：sample→agreement→α

技术红线 不能把 sampled agreement 合格写成“Recall@10 有理论下界”。

6.3 Budget Search, Nestedness and Tie Safety

600 words

写什么 给二分选择和同样本完整枚举，对嵌套的 primary candidate sets 与固定 refined-score total order 给出单调充分条件。

要论证 证明参考为最大候选全集 top-k 时，随着候选集嵌套扩大，交集个数不减；若实际 local quota/不同 tie/path 破坏嵌套，只能用 enumeration 在网格上检验。

数据 / 图 ADC M2 / v69 actual compile flags / current top-c implementation • F16：单调成立/失败用例

技术红线 不能机械照搬旧 ADC K_LOCAL=4 的证明或假设。

6.4 Budget Baselines and Their Questions

450 words

写什么 基线独立定义：fixed α=100、多个小 fixed α、same-sample enumeration、full-pool calibration、GT offline oracle。

要论证 说明每种比较回答的不同问题：简单策略是否足够、二分有没有漏掉采样准则最小值、有限样本代价、oracle gap。

数据 / 图 CAL v69 (pending) / older ADC historical • P0 budget controls table

技术红线 offline GT oracle 是不可部署理论参考，不等于公平在线算法。

6.5 Hold-out Risk, Calibration Cost and Payback

500 words

写什么 分别报告 selected-arm QPS、held-out ΔRecall/损失频率/最坏损失、S=128 校准时间与 reused batches 的 amortised net benefit。

要论证 仅当 T_fixed>T_rule 时 $N^*=T_{cal}/(T_{fixed}-T_{rule})$ 有正回本；讨论 query drift、校准频率、单位、置信波动；v69 1.03–1.69× 与 3.9–21.3 ms 尚待核。

数据 / 图 CAL-v69 USER-REPORTED / RAW budget_v69.log not available • F17：速度/质量/回本三联

技术红线 “10/12 更快”必须给出 fixed 对照、质量和是否包含校准开销。

6.6 Policy Failure Modes and Applicability

200 words

写什么 归纳小样本、reference 自身漏召、非嵌套选择、测量噪声、校准成本不回本和工作负载漂移。

要论证 将策略部署条件写成可以复核的限制，不承诺未测负载。

数据 / 图 CAL negative cases / Chapter 7 · policy guardrail table

技术红线 不要把未实现 online re-calibration 写作当前产品能力。

章节校验：本章 6 小节，建议 2,600 词。只将经过证据登记的数字写入强结论。

CHAPTER 07 · 6,800 ENGLISH WORDS · 8 SUBSECTIONS

Experimental Evaluation and Research Findings

以原始实验回答四个研究问题

EXAMINER QUESTION

每张图的设置可否复查？是否同时报告正反例、对手真正获胜的区间和内部消融的局限?

REQUIRED DELIVERABLE

现代 GPU ANN frontier、机制消融、分层正确性、预算风险、batch 取舍、建库/内存/规模和异常分析。

7.1 Final Experiment Manifest and Comparison Families

420 words

写什么 展示 E1、ADC six、PIPE、OPT、new v69 budget、v71 LUT、LARGE 的版本/硬件/index/query/metric/pipeline 差异。

要论证 用一张矩阵列实际 build commit、binary、train cache 和 run script；公共方法引用 Ch3，不复述定义。

数据 / 图 EVID-REG / E1 / PIPE / OPT / local PENDING · Table 7.1

技术红线 如果任何最新结果缺少日志，不可让它替代旧版历史图的实际数据。

7.2 Modern GPU ANN Recall–QPS Frontiers

1,300 words

写什么 E1 四数据集各画所有方法完整 Recall@10–QPS frontier（CAGRA fp32/int8、IVF-RaBitQ、IVF-PQ、exact GPU），并列 match=0.97 的表。

要论证 清楚说明 batch=1000/k=10/RTX5090；arxiv recall 0.97 与 IVF-RaBitQ 近似持平，低 recall CAGRA int8 领先，≥0.98 部分 IVF-RaBitQ 更快；匹配方式及插值/实测都可检查。

数据 / 图 E1 POSTER_CLAIMS / E1_matched / RAW / FAIR · F18：四数据集完整曲线

技术红线 不能只报单一点“全面最快”；不能把后续内部版本 speedup 乘到旧 E1。

7.3 Cartesian LUT, Packed Loads and Lane Refinement

850 words

写什么 统一固定表示/候选/参数，对 LUT G=1/2/4/8、packed load、lane L16 与必要对照做 paired ablation。

要论证 区分表字节、load/add/work、kernel stage time 和 end-to-end QPS；新 v71 22/24（其余 <1%）仅在原始核对后替换历史 23/24；浮点误差与 ties 也须纳入。

数据 / 图 ADC M1 historical / v71 USER-REPORTED / PIPE L16 · F19：机制消融多尺度图

技术红线 当差距小于 run-to-run 波动，写 near tie 而非胜负。

7.4 Global Top-c, Shared Bound and Probe Correctness/Ablation

1,200 words

写什么 分别给 3 套实验：A v61 vs v62 的 local top-c/merge；B v62 vs v63 的共享完整 key bound；C v65 vs v69 的 exact probe selection。

要论证 对 A 报按 stable position 的集合/顺序/tie、G/ck/batch 变化；B 给 top-c 完全一致与 stage cost；C 专用 1792 用例。可附 v65 234,320 对 final ID 的比较，但不得据此替代每层验证。

数据 / 图 PIPE_V62 / PIPE master / OPT / raw dumps · F20：正确性覆盖+性能并列

技术红线 牢记 v63 不减少 primary score 计算；probe case 不证明全局 top-c；同 Recall 不代表同结果。

7.5 Held-out Budget Quality, Throughput and Payback

900 words

写什么 用新 v69（若 raw 取得）画固定 α、多小固定预算、same-sample grid、full-pool 与 GT oracle 的 performance/quality/cost。

要论证 以统一 comparator 报 10/12 selected-arm 1.03–1.69×（待核），S=128 3.9–21.3ms（待核）、hold-out ΔRecall、失败率和净摊销；单列另两项失败。

数据 / 图 CAL-v69 local PENDING；ADC historical · F21：收益-风险-回本三联

技术红线 不得把 selected QPS 当含校准成本的整体 speedup。

7.6 Batch Regimes, G Scheduling and Workload Skew

680 words

写什么 给 b=8/32/256/1000 的 v61 L16、v62、v63、v65 同版本比较，配阶段 scan/merge/staging 时间。

要论证 解释 small batch block 不足和 large batch 重复成本；讨论 vogue 的 list-length skew、调度固定规则与 b=256 regret；报告 v61→v65 2.73×(b8) 与1.015×(b1000) 的内部口径。

数据 / 图 PIPE master / PIPE_V62 / trace stages • F22：QPS/batch + stage stack

技术红线 不要将 internal 2.73× 写成相对 CAGRA；不同 α、不同时间协议的结果不相乘。

7.7 Cold Construction, Resident Memory and Tested Scale

850 words

写什么 拆 cold build/training/encoding/assignment/reorder、常驻索引、workspace、peak memory；包括 ADC 历史 10M+/17.8M 案例和有原始报告时的 newer large retest。

要论证 对外比较须解释 JHQ process-minus-context vs baseline index-only；对无法运行的 baseline 说明 OOM 或设定；从实际字节模型讨论但不宣传 untested 1B。

数据 / 图 ADC / E1 fairness / newer LARGE PENDING • F23：stage-build + bytes/vector

技术红线 不能将计算复杂度上界当作真实时间规模律，不能把缓存读取算冷建库。

7.8 Numerical Robustness, Anomalies and Recall Attribution

600 words

写什么 报告 FP16 probe 集合微差、tie、rare 30–60ms RaBitQ calls、matched interpolation 与 measured point 可能相反，以及 budget tail-loss。

要论证 如有固定候选集合与 GT，给 A=accessed pool → C=primary winners → R=final 的 recall upper-bound funnel；无 counterfactual 则只称覆盖率界而不归因精排损失原因。

数据 / 图 E1 sensitivity / OPT / PIPE / CAL raw • F24：quality funnel（可选）

技术红线 不要只保留有利测点；不以同召回断言两实现数值完全相同。

章节校验：本章 8 小节，建议 6,800 词。只将经过证据登记的数字写入强结论。

CHAPTER 08 · 2,200 ENGLISH WORDS · 5 SUBSECTIONS

Discussion, Limitations and Future Research

从结果提炼可迁移的研究认识

EXAMINER QUESTION

能否从受控观察推导取舍，又诚实交代竞争解释、失败路线和可反驳的未来问题?

REQUIRED DELIVERABLE

三条跨层发现；两项深入负结果；有效性威胁；原创而可测试的下一步。

8.1 Three Cross-Layer Insights

850 words

写什么 认识 I：Cartesian 表示为 16+16 小表创造机会，但最优表由 GPU 访存/指令共同决定。II：更多 block 与重复 staging/merge 竞争。III：refine 变快可能改变校准节省空间。

要论证 每项按 Observation→Mechanism hypothesis→Alternative explanation→Counterexample→Decision 写。III 旧新预算收益差异只能作为机制待检验，不能称已经有因果证明。

数据 / 图 LUT / PIPE / CAL / RANK • Finding 1–3 evidence matrix

技术红线 不要把“GPU 并行重要”这种常识包装为原创洞察。

8.2 Two Deep Negative-Result Case Studies

650 words

写什么 正文选 Mailman GPU isolated scorer（最快仅为 baseline 的0.19–0.58×，未端到端集成）和 rank-optimal representation（有严格离线对照，部分 median 后续做了 GPU 测试）。

要论证 每例写原假设、实测/模拟/估算的证据等级、瓶颈诊断、为什么停止/调整；v64 transformed routing 的小收益与 tie drift 可作为第三个简短对照移附录。

数据 / 图 MAIL / RANK / OPT median / PIPE v64 • F25：NO-GO 机制与结论

技术红线 Mailman 的端到端减速仅为模型估算；rank-optimal 主报告没有完整 GPU kernel。

8.3 Threats to Internal and External Validity

350 words

写什么 讨论单 RTX 5090、batch=1000 的外部对比、数据分布、nlist/nprobe、训练预算、GT、FP/tie、测量轮次和不同显存口径。
要论证 为每个主要 claim 指定哪些威胁会导致它反转，以及已有控制措施；对不确定小差异写保守结论。
数据 / 图 E1 FAIR / PIPE / EVID ledger • 威胁→claim→缓解表
技术红线 未来在多 GPU 运行不是本研究已经解决这些威胁的证据。

8.4 Original Testable Research Directions

250 words

写什么 优先提出 tail-risk-constrained workload calibration、capacity-aware residual access 两个方向。
要论证 各写输入/优化变量、精确假设、最低可行实验、失败判据和相对已有方法的真正新意；cloud/S3 仅未来设想。
数据 / 图 CAL held-out / resident-memory / stage time • mini-proposal ×2
技术红线 已尝试的 rank-based thresholds 和 quota pilot 不得再次作为无人做过的“未来算法”。

8.5 Conditional Deployment Recommendation

100 words

写什么 在已测 recall、batch、GPU、内存预算范围内给出适合评估 JHQ-GPU 的条件，不宜时说明 CAGRA/RaBitQ 优势。
要论证 通过可验证条件总结工程价值，语气克制。
数据 / 图 E1 frontiers / CAL risk • 一句条件化建议
技术红线 不能承诺所有数据集和任意硬件下全面胜出。

章节校验：本章 5 小节，建议 2,200 词。只将经过证据登记的数字写入强结论。

CHAPTER 09 • 500 ENGLISH WORDS • 2 SUBSECTIONS

Conclusion

逐项回答研究问题，不能新造数字

EXAMINER QUESTION
最后一页能否精确说出三项成果及它们的证据边界?

REQUIRED DELIVERABLE
按 RQ1–RQ4 回答，归纳表示—执行—预算耦合的系统规律。

9.1 Answers to the Four Research Questions

400 words

写什么 每个 RQ 直接以“完成了什么 + 最稳的 1–2 个数据 + 条件 + 局限”收束。
要论证 引用已审核版本和相同对照；不在 conclusion 新引入未显示过的结果。
数据 / 图 FINAL claim register + Ch7 • RQ→证据简表
技术红线 绝不写 untested billion scale 或 universally fastest。

9.2 Closing Principle and Outlook

100 words

写什么 最后强调表示结构、GPU 执行、候选预算必须被端到端与质量风险共同评价。
要论证 给一个严格来自前文证据的未来假设作为结尾。
数据 / 图 Ch8 finding matrix • 短结语
技术红线 避免广告式口号和绝对化语言。

章节校验：本章 2 小节，建议 500 词。只将经过证据登记的数字写入强结论。

APPENDIX A / THE TECHNICAL PROOFS THAT MATTER

五个必须可审查的形式命题

这些命题是写作时的证明检查表。应在 Ch5/Ch6 给读者可理解的推导；具体实现条件、对抗案例和输出 dump 则放 thesis 附录。

A1 • CARTESIAN SPLIT LUT

$$||q - c(i,j)||^2 = ||q_A - a_i||^2 + ||q_B - b_j||^2$$

前提：码本是正交分块上的 Cartesian product，距离是可分加的平方 L2。实数恒等式不自动保证不同 CUDA 浮点求和顺序 bitwise 一致；测试 full 256 vs split 16+16 的 score/tie。

A2 • EXACT GLOBAL PRIMARY TOP-c

$$\mathrm{Top}_c(\cup_g U_g) = \mathrm{Top}_c(\cup_g \mathrm{Top}_c(U_g))$$

对固定已评分候选 U，使用相同、确定性严格全序 key=(primary score, stable position)。任一全局前 c 名在所属组内必属于 local top-c；合并局部有序表时每轮截取前 c 名保持不变量。若 local quota < c 则需要额外证明。

A3 • v63 SHARED COMPLETE-KEY UPPER BOUND

$$\mathrm{key}(x) > \tau \Rightarrow x \text{ cannot enter the global primary } \mathrm{Top}_c$$

若某组已得到 c 个完整评分 key，该组第 c 小 key 为全局第 c 小 key 的上界；atomicMin 维护跨组的较紧上界。与 position 一同比较，确保 tie-safe。此法不减少 full primary score 计算，而主要减少接纳、局部排序和合并。旧阈值只影响省工机会，错误低阈值会破坏正确性。

A4 • BUDGET-NESTEDNESS MONOTONICITY

$$C_\alpha \subseteq C_\beta \;\&\; \text{fixed refined total order} \Rightarrow \mathrm{overlap}(R_\alpha, R_{ref}) \le \mathrm{overlap}(R_\beta, R_{ref})$$

以最大预算的确定性 top-k 为参考。候选集合嵌套且重评分顺序固定，扩大集合不能淘汰一个已入选且属于全局参考 top-k 的候选。实际不精确 local quota、ties 或不同路径若破坏嵌套，此结论不可直接套用。

A5 • SAMPLE AGREEMENT DOES NOT IMPLY GT RECALL

$$\mathrm{Agreement}(R_\alpha, R_{ref}) = 1 \not\Rightarrow \mathrm{Recall}(R_\alpha, GT) = 1$$

大预算 reference 本身可能漏掉真实近邻。相同错误结果仍可达 100% agreement。因此校准与 GT hold-out 评价必然分开；epsilon 与 S 一起决定实际错误容忍比例。

> **设计审稿提醒：**35 页旧版提到的 “partial distance lower bound > threshold” 是另一类可能的安全提前终止技术。它若被采用，需要独立的非负下界和浮点界证明；当前 v63 共享的是完整 score 的上界，不能混在一起描述。

APPENDIX B / CORRECTNESS EVIDENCE LADDER

正确性不是一个 Recall@10 数字

层级	reference / 检查方法	能证明什么	不能证明什么
C0 编码与索引	CPU/FP64 构造/解码、ID、offset、rotation	表示按定义组织	不能证明搜索正确
C1 LUT	full vs split，Δscore、tie/order	拆表的数学/数值语义	不能证明 global top-c
C2 probe	centroid exact selection，1792 cases	被测 IVF list 选择	不能证明 candidate top-c
C3 global top-c	single-block 与 G=2/4/8、CPU primary oracle	被访问候选上的精确选择	不能证明 raw exact nearest neighbours
C4 shared bound	threshold off/on，全序 ties/并发	发布上界在测试/形式条件下安全	不能从 QPS 推出正确性
C5 residual refine	serial/高精度 vs L16 scores/top-k	并行归约的数值与排序影响	不等于 raw FP32 rerank
C6 end-to-end	固定 GT 的 Recall@10 与 held-out	完成检索的真实质量	不能证明所有 kernel 内部无 bug
C7 safety	compute-sanitizer + 多尺寸/seed	已覆盖的内存与同步路径安全	不能代替任何数学正确性

推荐的最小对抗覆盖

排序

完全相等 scores、阈值边缘、接近 FP ULP、±0/Inf/NaN 的规范化策略、重复原始 ID 与唯一 position。

数据形状

空/极短 list、候选总数小于 c、非 32 倍数维度、极大 nprobe、不均匀 list 长度。

并行

G=1/2/4/8、batch=1、大/小 ck、atomic 竞争、阈值尚未发布/晚发布、merge ping-pong。

> v62 报告与 v65 pipeline 报告已经提供了具体条件下的验证证据；正文只援引实际覆盖的范围。无法重跑的测试不得宣称“适用于所有输入”。

APPENDIX C / CLAIMS THAT MAY SURVIVE A GPU ANN REVIEW

三条跨实验研究发现如何写成论文

发现	已观察到的内容	可能解释与反例	还缺的判定条件
I · Representation × execution	可分 LUT/packed 与不同表示的性能变化。	更小表可能多 lookup 或增加 instruction/occupancy；不同数据分布会反转。	固定 index/candidate；报 table bytes、instructions/stage time、变化范围；v71 raw 待核。
II · Parallelism × redundant work	v62 小 batch 增益显著，大 batch fixed G 退化；v63 bound 和 v65 schedule 缓解。	SM 利用率不足 vs LUT/staging/merge 重复；可能与列表倾斜/调度开销有关。	paired stage time + candidate CV；对 b=256 误选点解释。
III · Faster refinement × policy economics	旧 ADC 与新 v69 的 selected-arm 区间不同；refine 相对成本会改变 α 的价值。	也可能来自 index、calibrator、alpha grid、二进制或计时协议变化。	同索引同 query、同 α 网格下更换 refine kernel，并计入 calibration。

可复用的研究段落逻辑

我们观察到 **O**，来自受控比较 **E**。在控制 **C** 后，机制 **M** 与现象一致；但 **M2** 也可能导致类似结果。反例 **F** 限制了适用范围。由此我们作出 **D** 的设计决策，并将尚未证实的假设 **H** 留给下一次实验。

Recall funnel：是覆盖率上界，不是自动的归因证明

A · Accessed pool
all candidates in probed IVF lists

$\supseteq$

C · Primary winners
Top_c(A, D_primary)

$\supseteq$

R · Final result
Top_k(C, D_refined)

相对同一 ground-truth 集合 G：$|G \cap A|/k \geqslant |G \cap C|/k \geqslant |G \cap R|/k$。前两项是可能的 recall 上界；若要区分 primary 与 refined ranking 对实际误差的贡献，需要固定候选全集并做 counterfactual rerank。

APPENDIX D / FIGURES BY EVIDENCE VALUE

优先画能证明论点的图，不按数量凑图

优先级	图	正文位置	读者必须从图看出什么
P0	F05 · Build/query architecture	Ch4	host/GPU 边界、常驻/临时数据和真实完成的 pipeline。
P0	F09 · Cartesian 256 → 16+16 LUT	Ch5.2	数学分解、表项数、查表次数、实际 stage latency。
P0	F11 · Exact global top-c proof diagram	Ch5.4	每组 local top-c、集合覆盖、merge 不变量、tie。
P0	F12 · v63 shared complete-key bound	Ch5.5	full score 后发 key、atomicMin、接纳/merge 省工；不是 partial score early exit。
P0	F18 · Four-dataset complete Recall–QPS frontiers	Ch7.2	包括低/高 recall 对手胜出区间、测点、插值、误差范围。
P0	F20 · Correctness ladder and top-c validation	Ch7.4	probe、top-c、threshold、refine、recall 与 sanitizer 各自验证。
P0	F21 · Budget quality and amortisation	Ch7.5	selected QPS、held-out ΔRecall、tail loss、T_cal、N* 单独呈现。
P1	F06 · Index physical layout	Ch4.3	list、position、packed code、residual、metadata 与地址公式。
P1	F19 · LUT / packed / lane ablations	Ch7.3	唯一改变变量、stage cost 与 end-to-end。
P1	F22 · Batch/G scheduling sensitivity	Ch7.6	small-batch 吞吐增益 vs large-batch staging+merge 重复。
P1	F23 · Construction and memory breakdown	Ch7.7	冷建库、index-resident、workspace、peak 的同口径或标注差异。
P1	F25 · Negative-result diagnostic	Ch8.2	Mailman isolated GPU 与 rank-optimal offline/GPU 状态明确区分。
P2	F24 · Stage-wise recall upper-bound funnel	Ch7.8	A→C→R 的上界，需固定 GT 与实际候选轨迹。

图注最低字段：dataset (N,d,metric)、GPU/driver、query batch、k、index snapshot、binary SHA、nlist/nprobe/α/G、时间口径、repetitions、是否插值、误差/波动，以及原始日志/绘图脚本入口。图画得漂亮不能替代这些字段。

APPENDIX E / READING PLAN WITH DIRECT SOURCES

15 篇分级必读/选读论文：读完直接能写

P0 是会改变方法新颖性或强基线评价的论文；P1 支持替代设计与负结果；P2 只补必要背景。建议每读一篇写五栏卡：研究约束 / 原论文技术选择 / 代价和反例 / 与 JHQ-GPU 的区别 / 可以放进 thesis 的具体论断。

P0 JHQ: Johnson-Lindenstrauss Enhanced Hierarchical Quantization

阅读目标：原始正交变换、Cartesian 主码、残差和误差条件；写出继承/新增边界。

建议引用位置：2.3 / 4.2 / 5.1 · 原文入口

P0 GPU-Native ANN Search with IVF-RaBitQ (PVLDB 2026)

阅读目标：重点看 GPU build、量化距离核与 fused search；对照本项目布局/精排/成本。

建议引用位置：2.6 / 7.2 · 原文入口

P0 Billion-scale Similarity Search with GPUs (Faiss)

阅读目标：WarpSelect 与 GPU top-k、压缩距离与 memory hierarchy；区分成熟原语和你的系统适配。

建议引用位置：2.4 / 5.4 · 原文入口

P0 Parallel Top-K Algorithms on GPU (SC 2023)

阅读目标：比较 selector 的并行方案；给 global top-c 和 merge 的 prior art 与边界。

建议引用位置：2.6 / 5.4 · 原文入口

P0 Quicker ADC: Unlocking the Hidden Potential of PQ with SIMD

阅读目标：split tables 的已有思想与 CPU SIMD 前提；解释你的 Cartesian exact split 有何不同。

建议引用位置：2.6 / 5.2 · 原文入口

P0 CAGRA: Highly Parallel Graph Construction and ANN Search

阅读目标：GPU 图结构、构建成本、负载与高 recall 区间；比较论文结果时统一实测硬件。

建议引用位置：2.5 / 7.2 · 原文入口

P0 RaBitQ: Quantizing High-Dimensional Vectors with a Theoretical Error Bound

阅读目标：哪些是距离估计界，哪些并不能推出系统端到端 recall 保证。

建议引用位置：2.6 / 7.2 · 原文入口

P1 Product Quantization for Nearest Neighbor Search

阅读目标：PQ/ADC/IVFADC 的严格数学与历史脉络，避免混淆残差对象。

建议引用位置：2.2 · 原文入口

P1 Practical and Asymptotically Optimal Quantization (multi-bit RaBitQ)

阅读目标：量化位宽与误差—空间取舍；9 bit/d 匹配不等于索引总显存相同。

建议引用位置：2.6 / 7.2 · 原文入口

P1 SONG: Approximate Nearest Neighbor Search on GPU

阅读目标：图搜索阶段解耦；指出通用 GPU 调度及何处需特化。

建议引用位置：2.5 / 8.1 · 原文入口

P1 BANG: Billion-Scale ANN Using a Single GPU

阅读目标：host/GPU 分工、压缩与超显存访问，作为容量设计的不同路线。

建议引用位置：2.5 / 8.3 · 原文入口

P1 Accelerating Large-Scale Inference with Anisotropic VQ (ScaNN)

阅读目标：理解排序质量不等于 MSE；解释已有 rank-optimal 负结果。

建议引用位置：2.6 / 8.2 · 原文入口

P1 Optimized Product Quantization

阅读目标：learned rotation/训练开销与 JHQ analytic 设计取舍。

建议引用位置：2.6 / 8.1 · 原文入口

P2 HNSW: Efficient and Robust ANN Search with Hierarchical Graph

阅读目标：图 ANN 的背景，主要用于说明与 IVF 的结构差异；不做长篇教程。

建议引用位置：2.5 · 原文入口

P2 Roofline: An Insightful Visual Performance Model

阅读目标：分析 arithmetic intensity 与 bandwidth 的条件解释；不能代替 counters。

建议引用位置：5.3 / 8.1 · 原文入口

> **先读顺序：**JHQ 原文 → GPU IVF-RaBitQ → Faiss GPU + SC23 top-k → Quicker ADC → CAGRA/RaBitQ。前五篇应直接改写你的 Ch2 gap、Ch5 设计取舍与 Ch7 baseline 讨论，而不只是增加引用条数。

APPENDIX F / EXAMINER GATES AND EXECUTION ORDER

最高档质量门槛：提交前逐项自审

G1 • Ownership
贡献表中原 JHQ 数学/现有 GPU primitives 与本人实现、系统设计、分析分明；无无依据“首创”。

G2 • Formal semantics
精确 primary top-c、v63 full-key bound、预算单调性的前提与源码/测试一致；tie/position 规则可查。

G3 • End-to-end evidence
所有 headline 数字对应具体 binary/index/query/RAW；不将 local v71/v69 未审记录伪装已核。

G4 • Fair comparison
CAGRA fp32/int8、IVF-RaBitQ、IVF-PQ 的完整有效区间均展示；同 recall 比较不外推。

G5 • Ablations
每项设计可指出唯一改变变量、stage cost、端到端收益和正确性结果；负结果并非选择性隐藏。

G6 • Calibration risk
固定小预算、枚举、full-pool、GT oracle 都解释清楚；tail recall loss 与校准回本真实报告。

G7 • Research insight
三条跨实验发现明确区分观察、受控归因和机制推测；至少两项 NO-GO 给出决策依据。

G8 • Presentation
每幅主图独立自明；同一术语/变量在所有章节一致；英文句子不含未经证据支持的强结论。

实际动笔的四轮顺序

Round A / Evidence freeze

先获取 Mac 本地 adc_v69 和 v71 raw、更新的大集日志；固定比对协议并填 claim ledger。不能核实的主张先收窄。

Round B / Formal methods

完成 5.4 exact top-c、5.5 v63 full-key bound、6.3 calibration 条件证明；映射代码与参考测试。

Round C / Results and interpretation

先把 Ch7 主图和表格编齐；围绕主结果写 Ch8 insights 与负结果，再反向改写 Related Work。

Round D / Examiner pass

逐一审查 claim→version→figure→boundary；删去仅为凑 27,500 词的重复背景和未测未来部署。

最终原则：这份蓝图以 90+ 的技术严谨度来组织论文，不以页数代替质量；最关键的不是哪个 GPU 内核“听起来先进”，而是哪些命题能被代码、正确性条件和真实数据共同支撑。课程提交规则、字数统计和截止时间以 Canvas/导师的最新要求为准。